



TECHNICAL UNIVERSITY
OF CLUJ-NAPOCA

SISTEM MULTI-AGENT DE SUPORT CLINIC PENTRU DECIZII ÎN DEPARTAMENTUL DE URGENȚĂ

Absolvent: Ember Darius-Robert

Coordonator științific: As. Drd. Ing. Roxana Ramona Szomiu

Universitatea Tehnică din Cluj-Napoca

Facultatea de Automatică și Calculatoare - Departamentul Calculatoare



15.07.2026



CUPRINS

1. **Introducere și contextul problemei**
2. **Obiectivele proiectului**
3. **Soluția propusă**
4. **Implementare**
5. **Testare și validare**
6. **Concluzii**





INTRODUCERE ÎN DOMENIU

Contextul problemei: decizia clinică în UPU (Unitatea Primiri Urgențe)

- **Triajul ESI** (5 niveluri) depinde de experiența umană
- **Sub-triaj** -> risc de mortalitate
- **Supra-triaj** -> risipă de resurse
- **Parcursul UPU** = lanț de decizii (acuitate -> internare -> diagnostic -> departament -> cod ICD), studiate de obicei separat
- **ML tabular** pe date UPU: verificabil, dar o singură sarcină, fără limbaj natural - *[Raita et al., 2019], [Xie et al., 2022 — benchmark MIMIC-IV-ED]*
- **LLM / Multi-Agent**: flexibil, conversațional, dar costisitor, greu de verificat, halucinații - *[Chen et al., 2025 — MAP], [Lu et al., 2024 — TriageAgent]*

Ideea lucrării: combinarea celor două direcții, astfel încât fiecare să compenseze slăbiciunea celeilalte



Obiectivul principal

Proiectarea și implementarea unui sistem multi-agent de sprijin al deciziei în UPU, cu **LLM** folosit exclusiv pentru înțelegerea **limbajului natural** și **XGBoost** pentru toate predicțiile clinice - care răspunde întrebării de cercetare: **cât de mult îmbunătățesc predicțiile datele colectate de asistent?**


Obiective specifice:

- **Să extragă** structurat informația din descrierea în limbaj natural
- **Să prezică în cascadă** acuitatea, dispoziția, diagnosticul, departamentul și codul ICD
- **Să evalueze** agentul-doctor **înainte și după** colectarea datelor suplimentare
- **Să implementeze și să valideze** agentul parser folosind mai multe LLM-uri comutabile
- **Să implementeze** o interfață web conversațională și să valideze rezultatele reproductibil, pe seturi de test reținute



Soluția propusă (1/2): arhitectura multi-agent

Cele șase sarcini executate de cei patru agenți



diagnosticul și departamentul sunt prezise de două ori: inițial (v3_base) și după asistent

Parser NLP (LLM)


Agent triaj

Agent doctor (x3)

Agent asistent




Soluția propusă (2/2): **cascada de predicție**



- Fiecare model primește **ieșirea prezisă** a etapei anterioare
- Evaluarea agentului-doctor **înainte și după** colectarea datelor de către agentul-asistent
- **DOAR** pacienții internați primesc **diagnostic + departament**, restul primesc un **rezumat de externare**!




Implementare (1/5): agenții și tool-urile lor





Implementare (2/5): fluxul de execuție





Implementare (3/5): interfata conversațională

ED Emergency Department Decision Support
Live multi-agent runtime · MIMIC-IV models · research prototype

Describe the patient's symptoms

The intake specialist will read this, ask any follow-up questions, and the care team (triage, physician, nurse) will work through the case live.

I am a 65 year old male, I woke up with a sharp pain in my chest and I feel dizzy. I also can't feel my right hand.

Examples: 1 2 3

Begin assessment

Asking the patient running... ▶

Agent is asking

Thank you. On a scale of 0 to 10, with 0 being no pain and 10 being the worst pain imaginable, what would you rate your chest pain?

5

Send

Intake is asking

Please review the information I extracted and correct anything that is wrong.

CHIEF COMPLAINTS

chest pain, dizziness, right hand paresthesia

PAIN (0-10, -1 UNKNOWN)

5

AGE

65

GENDER

male

ARRIVAL TRANSPORT

walk-in

MRN (SUBJECT_ID, -1 IF NEW)

17909008

PRIOR ADMISSIONS (-1 UNKNOWN)

3

PAST MEDICAL HISTORY

heart failure, diabetes


Confirm and continue to triage

- Dialog interactiv: asistentul cere câmpurile lipsă, valorile lipsă nu sunt forțate de către LLM



Implementare (4/5): interfața conversațională

- Nivelul de gravitate (**ESI**) + **dispoziția** de la **triaj**
- Categoria de **diagnostic** și **departamentul** de internare din predicția **inițială**






Implementare (5/5): tehnologii și structură

Stack tehnologic:

- Python, **CrewAI 1.9.3** (orchestrare agenți)
- **XGBoost** + scikit-learn (TF-IDF, calibrare, metrice)
- pandas, joblib, thefuzz
- **FastAPI** (server) + **React / Vite / Tailwind** (client)
- Rulează pe hardware obișnuit, fără GPU dedicat




- Preprocesare **identică** la antrenare și inferență (preprocessing.py)
+ căi centralizate (paths.py) -> fără scurgeri de informație,
artefacte versionate (v1/v2/v3)



Validare (1/4): metodologie și triaj

MIMIC-IV-ED: 418.083 cazuri utilizabile · split 80/20 stratificat (random_state=42) · test triaj: 83.617 cazuri · evaluare în cascadă pe ieșiri prezise

- Acuratețe exactă (acuitate, nivel **ESI**): **67,55%**
- **ESI la ± 1 nivel: 98,18%**
- Kappa ponderat pătratic: 0,645 · AUC macro: 0,886
- Sub-triaj: **15,56%** (reducere intenționată de la 17,67% în v2)
- Sensibilitate ESI 5: 26,82% (de la 21,8%) - compromis asumat: -0,46 p.p. acuratețe pentru siguranță clinică




Dispoziție de internare/externare(triaj): AUC 0,864 - doar prima estimare, rafinată apoi de **agentul-doctor**.



Validare (2/4): valoarea datelor colectate de agentul-asistent


Metrică (test 20.420 cazuri)	Înainte de asistent	După asistent
Diagnostic top-1 (13 clase)	60,09%	64,07%
Diagnostic top-5	90,56%	92,77%
Departament top-1 (11 clase)	60,66%	70,79%
F1 macro diagnostic	0,516	0,553



Compromis: la departament, câștigul se concentrează pe clasa majoritară - acuratețea echilibrată scade (49,6% → 45,2%); clasele chirurgicale minoritare regresează.



Validare (3/4): **dispoziția de internare/externare rafinată, validarea end-to-end și poziționarea**



- Dispoziție doctor: **AUC 0,914** (vs. 0,864 triaj), eroare de calibrare **0,0036** (aproape perfectă).
- Prag de producție **0,40** (calibrare izotonică).
- Câștig consistent pe **toate subgrupurile clinice** (vârstnici +7,7 p.p., internări anterioare +7,4 p.p.)

Prag	Acuratețe	Sub-triaj	Supra-triaj
0,15	75,01%	5,38%	36,38%
0,20	78,15%	7,62%	30,11%
0,40	83,33%	18,14%	15,81%
0,50	83,96%	23,51%	11,70%



Validare (4/4): Gemini 2.5 Flash vs. MedGemma – Parser NLP (250 c. generate)

Metrică	Gemini 2.5 Flash	MedGemma-4B
Fidelitatea parsării (Complaint Jaccard)	0,598	0,529
Acuitate - acuratețe exactă	66,0%	60,4%
Acuitate - toleranță 1 nivel	96,0%	92,8%
Sub-triaj critic (ESI 1-2 ratate)	9,2%	8,0%
Dispoziție - acuratețe (prag 0,40)	79,2%	78,4%
Dispoziție - aria sub curba ROC	0,888	0,873
Diagnostic – top-1	42,3%	42,3%
Departament – top-1	47,9%	49,7%
Cod ICD – strict, top-1	17,8%	17,2%



CONCLUZII

Contribuții / realizări:

- **Lanț complet de decizii UPU** modelat ca o cascadă de 5 predicții înlănțuite, nu o sarcină izolată
- **Separarea strictă a rolurilor:** LLM = limbaj, XGBoost = decizie → predicții verificabile și reproductibile
- **Evaluare înainte/după asistent:** +3,99 p.p. diagnostic, +10,13 p.p. departament - valoare clinică măsurată direct
- Dispoziție calibrată (AUC 0,914, ECE 0,0036) · triaj sigur (98,2% la ± 1 nivel, sub-triaj < 16%)

Direcții viitoare: optimizarea parserului LLM (principala sursă de cost), funcție de cost asimetrică pentru dispoziție, tratarea claselor minoritare, integrare cu dosarul electronic.



Vă mulțumesc! 16



BIBLIOGRAFIE

1. Johnson et al., *MIMIC-IV-ED, PhysioNet*, 2023.
2. Xie et al., *Benchmarking emergency department prediction models with machine learning and public electronic health records*, *Sci. Data*, 2022.
3. Raita et al., *Emergency department triage prediction of clinical outcomes using machine learning models*, *Crit. Care*, 2019.
4. Gilboy et al., *Emergency Severity Index (ESI): A Triage Tool for Emergency Department Care*, *AHRQ*, 2012.
5. Chen et al., *MAP: Multi-Agent Inpatient Pathways*, 2025.
6. Lu et al., *TriageAgent*, 2024.
7. Tyler et al., *AI in ED triage — a scoping review*, 2024.
8. Chen & Guestrin, *XGBoost: A Scalable Tree Boosting System*, *KDD*, 2016.
9. Ruiz Mejia & Rawat, *MedScrubCrew (CrewAI)*, 2025.
10. Lansiaux et al., *URGENTIAPARSE (FlauBERT + XGBoost)*, 2026.





BACKUP A – Calibrare izotonică, AUC, Kappa Ponderat Quadratic


- **Threshold = 0.5** -> internare pacienți a căror predicție de internare este $\geq 50\%$.
- **Threshold = 0.2** -> internare pacienți a căror predicție de internare este $\geq 20\%$
- **QWK (Kappa Ponderat)** = metrică de evaluare care ține cont de cât de depărtată e clasa prezisă de clasa reală, penalizează predicțiile depărtate (ex. ESI 5 în loc de ESI 2)
- **AUC Dispoziție** = modelul de internare/externare face o predicție corectă, independent de pragul ales
- **AUC (macro) acuitate** = modelul separă corect între clasele ESI, inclusiv cele rare, ponderând toate clasele egal.
- **ECE = Expected Calibration Error** = cât de bine corespund probabilitățile estimate de model cu probabilitățile reale. Un model bine echilibrat dacă prezice cu o încredere de 80%, înseamnă că acea predicție e corectă în 80% din cazuri





BACKUP B - Predicția codului ICD


- **Rollup** = cod ICD parțial (3 caractere)
- **Oracol (oracle)** = presupune Stage-1 a prezis corect categoria de diagnostic, predicțiile ICD sunt evaluate în interiorul categoriei corecte
- **E2E (End-to-end)** = categoria reală de diagnostic prezisă la Stage-1, evaluarea ține cont de erorile care aici se propagă la predicția codului ICD.
- **1/3 internări** au etichete ambigue + există **mii de coduri ICD** = motivul pentru care **codul ICD** exact e așa greu de prezis





BACKUP C – Compararea parserelor LLM

- **Flash** = per total mai bun în configurația curentă
- **MedGemma** = alternativă pentru confidențialitate/cost (auto-găzduit)
- **Fidelitate simptom / Complaint Jaccard** = cât de precis recuperează parser-ul LLM simptomele (chief complaints) din textul în limbaj natural (versus simptomele reale din datele tabulare). **Scor mai mare = mai bun.**





BACKUP D – Evoluția pe versiuni, verificare hiperparametri, limitări

- **Triaj v1→v2→v3** (66,7% → 68,0% → 67,55%, dar sub-triaj 17,67% → 15,56%)
- **Doctor: v1/v2** pe 14 clase vs v3 pe 13 clase (versiuni necomparabile, clasa ambiguă "Symptoms-Signs-III defined" exclusă)
- **Optuna + NSGA-II**: configurația manuală ≈ optimă (varianta inițială reselectată pe frontiera Pareto)
- **Importanța caracteristicilor: TF-IDF** text = **84,6%** din câștig → explică aportul „real dar limitat” al datelor de agentul-asistent

