

**UNIVERSITATEA TEHNICĂ**

DIN CLUJ-NAPOCA

**FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL CALCULATOARE**SINTEZA
proiectului de diplomă cu titlul:**SUPORT CLINIC PENTRU DECIZII ÎN DEPARTAMENTUL DE URGENȚĂ**Autor: **Darius-Robert EMBER**
Coordonator: **As. drd. ing. Roxana Ramona SZOMIU****1. Cerințele temei:**

Tema lucrării constă în proiectarea și implementarea unui sistem multi-agent de sprijin al deciziei clinice pentru Unitatea de Primiri Urgențe (UPU) care, pornind de la descrierea în limbaj natural a stării pacientului, să producă întregul lanț de decizii clinice: acuitatea de triaj pe scala ESI (Emergency Severity Index, între 1, cel mai grav, și 5), decizia de internare/externare, categoria de diagnostic, departamentul de internare și codul de diagnostic ICD (International Classification of Diseases). Cerințele-cheie sunt: predicții explicabile, verificabile și reproductibile, limitarea strictă a rolului modelului lingvistic mare (LLM) la înțelegerea limbajului natural, fără a interveni în decizia clinică, caracteristici de antrenare fără scurgeri de informație (data leakage), posibilitatea de a compara predicțiile înainte și după colectarea datelor suplimentare de către asistent (semne vitale, medicație, antecedente), rulare pe hardware obișnuit, rol strict consultativ (sub controlul personalului medical).

2. Soluții alese:

Soluția aleasă este o arhitectură multi-agent în Python, construită pe baza framework-ului CrewAI [9], cu patru agenți specializați: un agent Parser NLP bazat pe LLM, un agent de triaj, un agent-doctor și un agent-asistent, ultimii trei bazați pe modele de învățare automată. LLM-ul (comutabil între Gemini 2.5 Flash, accesat prin API, și MedGemma, autogăzduit) este folosit exclusiv pentru a transforma textul natural al pacientului într-o reprezentare structurată de câmpuri. Toate cele cinci predicții clinice sunt realizate de modele XGBoost [6] antrenate pe baza de date MIMIC-IV-ED [1] (~425.000 de prezentări reale la urgență, din care 418.083 utilizabile), înlănțuite în cascadă: ieșirea prezisă a fiecărei etape devine intrare pentru etapa următoare (acuitate → dispoziție → diagnostic → departament → cod ICD).

Textul simptomelor este vectorizat TF-IDF, cu preprocesare identică între antrenare și inferență. Modelul ML pe care se bazează agentul-doctor pentru prezicerea deciziei de internare/externare este calibrat izotonic, iar într-o etapă următoare face o predicție a codului ICD (International Classification Of Diseases) exact din interiorul categoriei de diagnostic prezise anterior. Evaluarea agentului-doctor se face în două momente, înainte și după datele colectate de agentul-asistent, permițând măsurarea directă a valorii acestora. O interfață web conversațională (FastAPI + React) poate fi rulată pentru a pune în funcțiune același echipaj de agenți ca varianta din linia de comandă.




Fig. 1. Fluxul propus: de la descrierea pacientului în limbaj natural, prin parserul LLM, la cascada de agenți (triaj, doctor, asistent) și raportul final.

3. Rezultate obținute:

Pe setul de test cu 83.617 cazuri, modelul ML antrenat pentru a prezice nivelul de gravitate (scorul ESI) atinge 67,55% acuratețe exactă și 98,18% la toleranță de un nivel (ex. Prezicerea nivelului ESI 2 în loc de ESI 3), cu o rată de sub-triaj (atribuirea unui nivel de gravitate mai mic decât ar trebui) de 15,56%, orientată spre siguranța pacientului. Modelul care decide internarea/externarea prin intermediul doctorului obține o arie sub curba ROC de 0,914 și o eroare de calibrare de doar 0,0036. Răspunsul la întrebarea de cercetare este că datele colectate de asistent aduc o îmbunătățire de +3,99 puncte procentuale la predicția diagnosticului (top-1) și de +10,13 puncte la cea a departamentului. Predicția codului ICD exact atinge ~33% pe prima poziție (top-1) și până la 91% cu metrice gradate (codul ICD exact prezis greșit primește un scor parțial în funcție de cât de aproape a fost de cel corect) pe primele cinci coduri (top-5), ambele în varianta oracol, care presupune că în etapa anterioară categoria de diagnostic a fost aleasă corect.

Tab. 1. Efectul datelor colectate de asistent asupra predicțiilor doctorului (20.420 cazuri de test): acuratețe top-k înainte (bază) și după (post-asistent).

Predicție	Variantă	Top-1	Top-3	Top-5
Diagnostic (13 clase)	bază	60,09%	82,71%	90,56%
	post-asistent	64,07%	85,72%	92,77%
Departament (11 servicii)	bază	60,66%	92,28%	97,55%
	post-asistent	70,79%	94,08%	97,97%

Tab. 2. Performanța modelului de acuitate pe fiecare nivel ESI (precizie, recall, F1, număr de cazuri în setul de test).

Clasă ESI	Precizie	Recall	F1	Cazuri
ESI 1 (resuscitare)	57,36%	60,30%	58,79%	4.803
ESI 2 (critic)	63,62%	70,83%	67,04%	27.882

ESI 3 (urgent)	77,79%	67,23%	72,12%	45.012
ESI 4 (mai puțin urgent)	42,39%	61,67%	50,24%	5.700
ESI 5 (non-urgent)	17,77%	26,82%	21,38%	220

4. Testări și verificări:

Toate modelele au fost evaluate pe seturi de test reținute din MIMIC-IV-ED, cu o împărțire stratificată 80/20 și random_state fixat pentru reproductibilitate exactă. Sistemul complet a fost validat integral pe 250 de cazuri sintetice exprimate în limbaj natural, evaluate în patru moduri care izolează costul parserului LLM de cel al cascadei de predicție. Cele două parsere de limbaj (Gemini Flash vs. MedGemma) au fost comparate, s-a verificat alegerea hiperparametrilor printr-un studiu dedicat (Optuna [7], cu căutare multi-obiectiv NSAGA-II [8] pentru acuitate) și s-a analizat robustețea dispoziției de internare/externare pe subgrupuri clinice (ex. vârstnici, sau cei cu internări anterioare), împreună cu ratele de sub-/supra-triaj și calitatea calibrării probabilităților.

Tab. 3. Comparația celor două LLM-uri de parsare, evaluate identic pe cele 250 de cazuri în limbaj natural.

Metrică	Gemini 2.5 Flash	MedGemma
Fidelitatea parsării (Jaccard simptome)	0,598	0,529
Acuitate - acuratețe exactă	66,0%	60,4%
Acuitate - toleranță un nivel	96,0%	92,8%
Sub-triaj critic (ESI 1-2 ratate)	9,2%	8,0%
Dispoziție - acuratețe (prag 0,40)	79,2%	78,4%
Dispoziție - arie sub curba ROC	0,888	0,873
Diagnostic - top-1	42,3%	42,3%
Departament - top-1	47,9%	49,7%
Cod ICD - strict, top-1	17,8%	17,2%

5. Contribuții personale:

Contribuțiile personale includ: modelarea completă a lanțului de decizii din UPU ca o cascadă de cinci predicții înlanțuite, evaluată pe ieșiri prezise, nu pe răspunsuri corecte (erorile se propagă înainte în lanțul de decizii, iar o predicție anterioară greșită va influența predicția etapei următoare, care primește ca intrare predicția etapei anterioare); separarea strictă a rolurilor între LLM (doar parsare) și modelele supervizate verificabile și reproductibile (toate deciziile clinice); proiectarea evaluării doctorului în două momente, care măsoară direct valoarea clinică a datelor colectate de asistent; modelul dedicat de dispoziție cu calibrare izotonică și etapa de determinare a codului ICD exact; backend-ul de parsare LLM comutabil; pipeline-urile de antrenare, suita de benchmark-uri (pe date tabulare, pe cazurile generate și rulate prin fluxul integral, pe parserele de limbaj natural, studiul hiperparametrilor – Optun [7]) reproductibile și interfața web conversațională.


6. Surse de documentare:

- [1] A. Johnson, L. Bulgarelli, T. Pollard, S. Horng, L. A. Celi, R. Mark, „MIMIC-IV-ED (version 2.2)”, PhysioNet, 2023, doi: 10.13026/5ntk-km72.
- [2] N. Gilboy, P. Tanabe, D. Travers, A. M. Rosenau, „Emergency Severity Index (ESI): A Triage Tool for Emergency Department Care, Version 4”, AHRQ Publication No. 12-0014, 2012.

- [3] F. Xie et al., „Benchmarking emergency department prediction models with machine learning and public electronic health records”, Scientific Data, vol. 9, art. 658, 2022.
- [4] S. Tyler et al., „Use of Artificial Intelligence in Triage in Hospital Emergency Departments: A Scoping Review”, Cureus, vol. 16, nr. 5, e59906, 2024.
- [5] Y. Liu et al., „Benchmarking large language model-based agent systems for clinical decision tasks”, npj Digital Medicine, vol. 9, art. 259, 2026.
- [6] T. Chen, C. Guestrin, „XGBoost: A Scalable Tree Boosting System”, in Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining (KDD '16), pp. 785–794, 2016.
- [7] T. Akiba, S. Sano, T. Yanase, T. Ohta, M. Koyama, „Optuna: A Next-generation Hyperparameter Optimization Framework”, in Proc. 25th ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining (KDD '19), pp. 2623–2631, 2019.
- [8] K. Deb, A. Pratap, S. Agarwal, T. Meyarivan, „A Fast and Elitist Multiobjective Genetic Algorithm: NSGA-II”, IEEE Transactions on Evolutionary Computation, vol. 6, nr. 2, pp. 182–197, 2002.
- [9] crewAI Inc., „CrewAI: Framework for Orchestrating Role-Playing, Autonomous AI Agents”, <https://github.com/crewAIInc/crewAI>, 2025

Data: 13.07.2026

Autor Ember Darius-Robert



Coordonator _____